

실습으로 배우는 LangGraph : 내 손으로 RAG 시스템 만들기

제 9 차시

임베딩 이해

컴퓨터는 어떻게 '비슷한 뜻'을 알까

단어가 안 겹쳐도 찾아내는 원리를 들여다봅니다



이번 차시에서 배우는 것

01

벡터로 바뀌는 원리

텍스트가 숫자가 되는
과정을 직관으로 잡는다

02

코사인 유사도

두 문장의 의미 거리를
직접 재본다

03

키워드 vs 의미 검색

결정적 차이가
무엇인지 확인한다

04

나의 임계값 찾기

몇 점부터 관련 있다고
볼지 스스로 정한다

05

모델 고르는 기준

무엇을 보고 골라야
하는지 안다

06

실패 원인 진단

검색 실패를 임베딩
관점에서 분석한다

8차시에서 놓친 질문 하나

문서에는 "반품 절차"라고만 적혀 있는데, "환불 규정"이라고 물어도 찾아졌습니다

"환불"과 "반품"은 글자가 하나도 안 겹칩니다. "규정"과 "절차"도 마찬가지입니다.



Ctrl+F로 찾으면

절대 나오지 않습니다



의미 검색이라면

뜻이 통하면 찾아냅니다

그 비밀이 바로 임베딩입니다

글자가 겹쳐야만 찾는다면

사용자는 문서와 똑같은 단어를 쓰지 않습니다. 이런 질문이 전부 실패합니다.

"환불" 로 검색



문서엔 "반품"이라 적힘

실패

"비밀번호 변경"



문서엔 "패스워드 재설정"

실패

"얼마예요?"



문서엔 "가격은 100,000원"

실패

"고장났어요"



문서엔 "제품 불량 시"

실패

해결책은 두 가지입니다

① 동의어 사전을 사람이 계속 관리한다 (지옥입니다)

② 의미로 검색한다 ← 우리가 쓰는 방법

사람이 동의어를 알려준 게 아닙니다

"환불" 과 "반품"

비슷한 문맥에서 함께 등장합니다.
→ 그래서 비슷한 좌표를 받습니다.

"환불" 과 "점심"

함께 등장하는 일이 거의 없습니다.
→ 그래서 먼 좌표를 받습니다.

왜 숫자가 수백 개나 될까

지도는 위도·경도 두 개면 충분합니다. 평면 위의 위치니까요.
하지만 문장의 의미는 훨씬 복잡합니다 — 주제 · 감정 · 격식 · 시제 · 대상, 그리고 수백 가지 더.
이 모든 것을 담으려면 축이 많아야 합니다. 그래서 1536개의 숫자를 씁니다.

핵심 용어

임베딩

텍스트를 숫자 벡터로 바꾸는 것. 의미를 좌표로 옮기는 작업입니다.

벡터

숫자들의 목록. [0.21, -0.88, 0.05, ...] 형태입니다.

차원

벡터에 들어 있는 숫자의 개수. 1536개면 1536차원입니다.

코사인 유사도

두 벡터의 각도로 유사도를 재는 방법. 1에 가까울수록 비슷합니다.

의미 공간

비슷한 뜻의 문장이 서로 가까이 모이는 가상의 지도.

의미 검색

단어가 겹치지 않아도 뜻으로 찾아내는 검색 방식.

각도로 재는 이유

두 사람이 같은 자리에서 출발합니다. 어느 쪽을 보고 있느냐만 봅니다.

같은 방향

각도 0°

유사도 1.0

완전히 같은 뜻

90도 틀어짐

각도 90°

유사도 0.0

전혀 무관

정반대

각도 180°

유사도 -1.0


반대 뜻

거리가 아니라 방향을 봅니다

문장이 길든 짧은 상관없이 "어느 쪽 이야기인가"만 따집니다.

그래서 한 줄짜리 질문과 긴 문단을 비교해도 제대로 된 점수가 나옵니다.

실제로 재보면 이렇게 나옵니다



여기서 확인할 것

"환불 규정" ↔ "반품 절차"
글자가 하나도 안 겹칩니다.
Ctrl+F로는 못 찾습니다.

그런데 0.782가 나옵니다.

반면 "점심 메뉴"는 0.203.
관련 있는 것과 없는 것이
확실히 갈립니다.

이것이 의미 검색의 힘입니다

점수를 어떻게 읽을까

점수	해석	예시
0.9 이상	거의 같은 뜻	"환불 규정" ↔ "환불 정책"
0.7 ~ 0.9	관련 있음	"환불 규정" ↔ "반품 절차"
0.5 ~ 0.7	약하게 관련	"환불 규정" ↔ "배송 안내"
0.5 미만	무관	"환불 규정" ↔ "점심 메뉴"

이 기준은 절대적이지 않습니다

모델마다, 문서 종류마다 점수 분포가 다릅니다. 무관한 것이 0.6이 나오는 문서도 있습니다.

그래서 직접 측정해서 내 기준을 잡아야 합니다. 다음 슬라이드에서 그 방법을 봅니다.

내 기준선 찾기

기준 문장 하나를 정하고, 관련 질문 5개와 무관한 질문 5개의 점수를 재봅니다.

관련 있는 질문

- 0.823 환불 신청 기한 알려주세요
- 0.751 구매 취소 기간이 어떻게 되나요?
- 0.712 반품하고 싶어요
- 0.688 돈 돌려받을 수 있나요?
- 0.634 물건 안 마음에 들면 어떡하죠?

→ 최저 0.634

관련 없는 질문

- 0.311 대표이사가 누구인가요?
- 0.284 회사 주차장은 어디인가요?
- 0.267 직원 복지 제도 알려주세요
- 0.196 채용 공고 보고 싶어요
- 0.152 오늘 날씨 어때요?

→ 최고 0.311

두 값의 가운데 = 0.47 → 내 문서의 임계값

"유사도가 0.47 미만이면 관련 문서가 없다고 판단한다" — 이렇게 정해두면 억지 답변을 막을 수 있습니다

임베딩 모델 고르는 기준

기준	확인할 점	권장
한국어 성능	한글 문장을 제대로 구분하는가	다국어 지원 모델 필수
차원 수	클수록 정밀하지만 무거움	1536 전후가 무난
비용	문서량 × 차원에 비례	small 계열로 시작
일관성	인덱싱과 질의에 같은 모델인가	반드시 동일해야 함
로컬 여부	외부 전송이 불가한 문서인가	민감 문서는 로컬 모델

처음에 신중해야 합니다 — 나중에 바꾸면 전부 다시 만들어야 합니다

문서가 많을수록 재생성 비용과 시간이 커집니다. 모델명을 설정 파일에 고정해두세요.

대표 모델 비교

모델	차원	특징
text-embedding-3-small	1536	이 과정의 기본. 저렴하고 한글도 괜찮음
text-embedding-3-large	3072	더 정확하지만 비용·용량이 큼
ko-sroberta-multitask	768	한국어 특화. 로컬 실행 가능(무료)
bge-m3	1024	다국어 강세. 로컬 실행 가능

인덱싱과 검색에 반드시 같은 모델을 써야 합니다

모델마다 좌표계가 완전히 다릅니다. A모델의 (37.5, 127.0)과 B모델의 (37.5, 127.0)은 전혀 다른 장소를 가리킵니다. 모델을 바꾸면 저장된 벡터를 전부 다시 만들어야 합니다.

왜 못 찾았는지 순위로 확인하기

질문과 모든 조각의 유사도를 재서 순위를 보면, 어느 단계가 문제인지 좁혀집니다.



정답 조각이 1~3위에 있다

검색은 정상입니다

생성(프롬프트) 문제 — 13차시



정답 조각이 5~10위쯤 있다

거의 다 왔습니다

k값을 늘리면 해결 — 11차시



정답 조각의 점수가 아주 낮다

표현 차이가 큼니다

질의 재작성이 필요 — 30차시



정답 조각이 이상하게 잘려 있다

분할 문제입니다

chunk_size 조정 — 7차시

자주 하는 오해

× 임베딩은 문서를 요약·압축하는 것이다

요약이 아닙니다. 의미를 좌표로 옮길 뿐, 원문은 따로 보관됩니다

× 벡터를 보면 원래 문장을 복원할 수 있다

복원할 수 없습니다. 그래서 원문을 반드시 함께 저장합니다

× 차원이 클수록 무조건 좋다

정확도는 조금 오르지만 비용·용량이 크게 늘어 실익이 적을 수 있습니다

× 임베딩만 좋으면 검색이 잘 된다

분할이 엉망이면 아무리 좋은 임베딩도 소용없습니다

× 인덱싱과 검색에 다른 모델을 써도 된다

절대 안 됩니다. 좌표계가 달라 검색이 완전히 망가집니다

× 유사도 0.5면 무조건 관련 있다

모델·문서마다 분포가 다릅니다. 직접 측정해 기준을 잡아야 합니다

WEAKNESSES

의미 검색에도 약점이 있습니다

고유명사 · 숫자에 약하다

"제품코드 A-7742" 같은 건

의미가 없어서 정확히 못 찾습니다

부정문을 잘 구분 못한다

"환불이 가능하다" ↔ "불가능하다"

뜻은 정반대인데 유사도가 높게 나옵니다

최신 용어를 모를 수 있다

모델 학습 이후 생긴 신조어는

좌표가 어색하게 잡힙니다

그래서 실무에서는 키워드 검색과 함께 씁니다 — 하이브리드 검색, 33차시

이번 차시 체크리스트

개념 이해

- ☐ 임베딩을 지도 좌표 비유로 설명할 수 있다
- ☐ 차원이 왜 수백~수천 개인지 안다
- ☐ 코사인 유사도가 각도로 재는 것임을 안다
- ☐ 키워드 검색과 의미 검색의 차이를 설명한다
- ☐ 모델을 바꾸면 왜 재생성이 필요한지 안다

실습

- ☐ 벡터의 차원 수와 실제 숫자를 출력해봤다
- ☐ 여러 문장 쌍의 유사도를 측정했다
- ☐ 단어가 안 겹쳐도 점수가 높은 것을 확인했다
- ☐ 관련/무관 그룹으로 나의 임계값을 정했다
- ☐ 8차시 실패 사례를 임베딩으로 분석했다

이번 차시 과제

1

나의 임계값 찾기

내 문서 주제로 관련 질문 5개, 무관 질문 5개를
만들어 임계값을 구하고 기록하세요

2

유사도 표 만들기

문서에 자주 쓰이는 표현 5개를 고르고
사용자가 쓸 법한 다른 표현과 재보세요

3

부정문 실험


"환불이 가능합니다" ↔ "불가능합니다"
예상보다 높게 나옵니다. 왜일지 생각해
보세요

1번에서 구한 임계값은 10·11·14차시에서 계속 씁니다

NEXT

다음 차시 미리보기 — 10차시 벡터저장소 이해

오늘 좌표를 만드는 법을 배웠습니다. 그런데 조각이 수만 개라면 어떻게 될까요?



질문 하나에 5만 번 계산을 할 수는 없습니다

인덱스를 저장해두면 프로그램을 켜다 켜도 임베딩 비용을 다시 내지 않아도 됩니다.

개발 속도가 완전히 달라집니다.

마무리

마법이 아니라 함께 쓰이는 말을 세어둔 것

임베딩은 RAG에서 가장 마법 같은 부분입니다. 컴퓨터가 뜻을 이해하는 것처럼 보이니까요.
하지만 실제로는 방대한 글을 읽으며 "어떤 말들이 함께 쓰이는가"를 숫자로 정리해둔 것뿐입니다.

원리를 알면 한계도 보이고, 한계를 알면 대응할 수 있습니다

부정문을 구분 못 하고 고유명사에 약한 이유가 여기 있습니다

10차시에서 만나요.

